

Моделирование настроения новостей

Кармазин Василий ПИН-43
Уманский Александр ПИН-43

17 Декабря 2019

1 Вступление

Каждый день мы встречаемся с различными новостями. Информация идёт отовсюду: телевидение интернет, радио, социальные сети. И зачастую новости имеют негативный окрас. Поэтому мы решили улучшить новостные фильтры, чтобы люди могли защитить себя, детей от негативного или неприемлемого контента.

2 Обработка новостей

Мы использовали данные из открытых источников.¹ Данные включают в себя 8263 различные новостные статьи с тремя различными метками оценки настроения: *Негативные*, *Позитивные*, *Нейтральные*. (Рис. 1).

¹<https://www.kaggle.com/c/sentiment-analysis-in-russian>

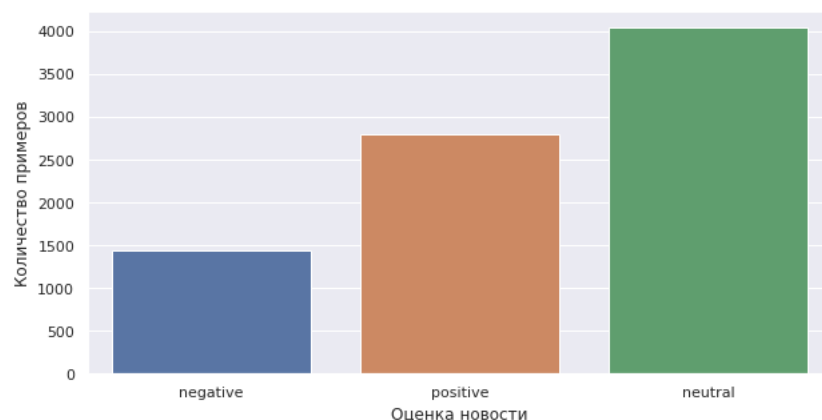


Рис. 1: Распределение настроения новостей в данных

Откажемся от части информации в данных, которые упростят эксперимент, а также избавимся от выбросов и аномалий.

Наши ограничения:

- Возьмём из новостей только русские слова
- Приведём все слова к нормальной форме через библиотеку `rumorphy2`².
- Не будем использовать новостные статьи, где больше 10000 символов

После данной обработки осталось 7732 статьи.

3 Описание моделей

Мы попробуем два метода:

Наивный, который основывается на построении множеств для каждого класса и взвешивания их частоты встречаемости в статьях.

Статистический, преобразуем наши данные так, чтобы можно было воспользоваться статистическими методами, а именно, логистической регрессией.

Проверить качество моделей будем метрикой F1-score³

²<https://pymorphy2.readthedocs.io>

³<https://en.wikipedia.org/wiki/F1-score>

3.1 Наивный метод

Сначала построим множества слов для каждого класса статей: S_{neg} , S_{pos} , S_{neu} - множества слов из статей с негативной, позитивной и нейтральной меткой, соответственно.

Построим множества уникальных слов для множеств S_{neg} и S_{pos} .

$$W_{neg} = S_{neg}/S_{pos} \text{ и } W_{pos} = S_{pos}/S_{neg}$$

Пусть $Freq_y(x)$ - функция, которая определяет частоту встречаемости слова x в множестве y . Тогда для оценки настроения новости воспользуемся простым алгоритмом. (Algorithm 1).

```
sentiment = 0
for word in words do
  if word in W_pos then
    word_freq = Freq_neg(word)
    polarity = 1
  end
  if word in W_pos then
    word_freq = Freq_pos(word)
    polarity = -1
  end
  if word in W_neu then
    neutral_freq = Freq_neu(word)
    if word_freq >  $\frac{neutral\_freq}{2}$  then
      sentiment +=  $\frac{word\_freq * polarity}{2}$ 
      continue
    end
    if neutral_freq > word_freq then
      continue
    end
    sentiment += word_freq * polarity
  end
end
```

Algorithm 1: Оценка настроения новостной статьи

Пройдёмся по всем словам статьи, проверяем имеется ли слово в W_{pos} или W_{neg} , если да, то сравниваем частоты встречаемости этого слова относительно *Нейтральных*. Суммируем все слова статьи и получаем общую оценку настроения статьи.

Дальше нормируем оценку на количество слов в тексте и подбираем два порога, которые будут определять нейтральную часть.

3.2 Логистическая регрессия

Преобразуем текст в численные значения, чтобы на них обучить логистическую регрессию.

Будем использовать TF-IDF⁴ - это статистическая мера оценки важности слова, основываясь на частотах встречаемости слова в тексте и в документе.

Частота слова t в документе d :

$$tf(t, d) = \frac{n_t}{\sum_k n_k}$$

Обратная частота документа:

$$idf(t, D) = \log \frac{|D|}{|\{d_i \in D | t \in d_i\}|}$$

TF-IDF является произведением двух сомножителей:

$$tf-idf(t, d, D) = tf(t, d) \times idf(t, D)$$

На самом деле, **TF-IDF** можно применять не только к одним словам, но и к нескольким, тем самым считая меру важности комбинаций слов, или применять к нескольким символам: униграммам, биграммам, триграммам и тд.

Мы будем использовать все три статистики, но стоит учесть, что это много информации, в том числе и лишней, поэтому мы выберем $N = 30000$ самых часто встречаемых случаев.

Тогда текст статьи представляется в виде вектора $news_{vector} \in \mathcal{R}^N$, где по элементам 0, если в тексте нет слова, и $tf-idf(\text{слова})$, если есть.

На $news_{vector}$ векторах будем строить многоклассовую логистическую регрессию, которую называют Softmax Regression⁵.

⁴<https://ru.wikipedia.org/wiki/TF-IDF>

⁵<http://deeplearning.stanford.edu/tutorial/supervised/SoftmaxRegression/>

4 Эксперименты

Наивный метод показал, что он хорошо различает между собой хорошие и плохие новости, а вот нейтральные сильно путаются, что видно на распределении нормированной оценки (Рис. 2).




Рис. 2: Распределение нормированной оценки настроения

Результаты множества слов.

- В хороших словах встречаются такие: делегация, экспедиция, упражнение, наставник, транскаспийский и тд.
- В плохих словах: терентьев, оштрафовать, взяточничество, тюремный, вирус, санкционирование и тд.

Подобрали пороговые коэффициенты: если оценка текста выше 0.1, то он позитивный, если ниже -0.05, то негативный, иначе нейтральный.




Рис. 3: Матрица ошибок наивной модели

На матрице ошибок наивного метода (Рис. 3). видно, что модель никогда не путает хорошие новости с плохими и наоборот.

Основные метрики по наивной модели

	precision	recall	f1-score	support
negative	0.73	0.68	0.71	1337
neutral	0.66	0.72	0.69	3734
positive	0.70	0.63	0.66	2661

Логистическая регрессия показала лучше результат, в целом, она распознаёт больше статей и меньше ошибается (Рис. 4). В этой модели иногда бывают ошибки между хорошими и плохими новостями, но такие ошибки очень редкие, ими можно пренебречь.




Рис. 4: Матрица ошибок многоклассовой логистической регрессии

По матрице ошибок видно, что модель чаще путает позитивные и негативные классы с нейтральными, чем между самими классами. По метрикам модель имеет сильно лучше результат, чем наивный метод.

Основные метрики по логистической регрессии

	precision	recall	f1-score	support
negative	0.89	0.82	0.85	1337
neutral	0.87	0.90	0.88	3734
positive	0.89	0.88	0.88	2661

Код экспериментов находится в открытом доступе⁶

5 Исследование модели

Хочется узнать, почему наша модель делает те или иные выводы про новости, на что модель обращает внимание, какие у неё есть недостатки.

5.1 Важность слов для модели

Визуализируем веса логистической регрессии, тем самым покажем важность слов для каждой категории новостей (Рис. 5).

⁶<https://github.com/elfour15f/math-modeling-institute>

y=negative top features		y=neutral top features		y=positive top features	
Weight ²	Feature	Weight ²	Feature	Weight ²	Feature
+1.497	word:не	+1.144	word:ноябрь	+1.137	word:ребёнок
+1.353	word:ндс	+0.909	word:университет	+1.042	word:ергожин
+1.187	char: не	+0.815	word:грипп	+0.928	word:август
+1.124	word:ктж	+0.801	word:изделие	+0.828	word:рубль
+1.045	word:бишимбаев	+0.788	word:назначить	+0.823	word:лёгкий
+1.040	word:сократиться	+0.765	word:тариф на	+0.815	word:соревнование
+1.001	word:из за	+0.758	word:депутат	+0.790	word:июнь
+0.987	word:суд	+0.754	word:взрыв	+0.788	word:пк
+0.982	word:шахта	... 15325 more positive ...		+0.771	word:женщина
+0.956	word:убыток	... 14656 more negative 14382 more positive ...	
+0.941	word:инцидент	-0.761	word:компро	... 15599 more negative ...	
+0.925	word:произойти	-0.763	word:миллион тенг	-0.769	char:не
+0.909	word:коррупционный	-0.765	word:куандык	-0.783	word:какой
+0.900	word:арестовать	-0.772	word:жангуразовый	-0.785	word:произойти
+0.888	word:куандык	-0.788	word:шымкент	-0.805	word:на
+0.841	word:куандык бишимбаев	-0.796	word:казавтопром	-0.822	word:причина
+0.825	word:долг	-0.819	word:ергожин	-0.865	word:убыток
+0.809	word:что	-0.841	word:июнь	-0.872	word:из за
+0.809	word:единица	-0.898	word:сентябрь	-1.111	word:что
+0.785	word:рейтинг	-0.904	word:август	-1.131	word:суд
... 12744 more positive ...		-0.916	word:самолёт	-1.241	char: не
... 17237 more negative ...		-0.969	word:поезд	-1.649	word:не

Рис. 5: Веса логистической регрессии

По словам можно заметить, что выборка новостей из Казахстана и связана с политикой, это даёт сильное смещение, что не очень хорошо. Это можно видеть по словам: **бишимбаев**, **ергожин**, **ктж** (Казахстанские железные дороги). Печально, что модель считает, что слова **взрыв** и **грипп** нейтральными. В позитивных словах не видно зависимостей.

5.2 Поведение на Зеленоградских новостях

Мы решили проверить модель на Зеленоградских новостях. Для сокращения, приведём только заголовок статьи и оставим ссылки на источник.

Результаты модели на наших новостях

Результат модели	Заголовок новости
neutral	На «зебре» у поликлиники автомобиль наехал на женщину с ребенком ⁷
negative	Вандалов осудили за порчу детской площадки и осквернение подъезда дома ⁸
neutral	В январе проезд по Новой Ленинградке ночью с транспондером сделают бесплатным ⁹
negative	На новой «зебре» в 11-м микрорайоне сбили ребенка ¹⁰
neutral	Очевидец заснял уснувшего перед светофором таксиста ¹¹
positive	Матвей Елисеев трижды попал в тридцатку лучших на Кубке мира ¹²
negative	Женщине присудили 230 тысяч рублей за падение на лестнице у ТЦ «Столица» ¹³
neutral	На месте регбийного поля у 5-го микрорайона собираются построить стадион ¹⁴
positive	Врачи горбольницы спасли девушку после ДТП и вернули ей возможность ходить ¹⁵
neutral	Власти Зеленограда одобрили проект реновации 19-го микрорайона ¹⁶

Поведение на небольшой выборке из 10 новостей.

⁷<https://www.netall.ru/incidents/news/1136839.html>

⁸<https://www.netall.ru/society/news/1136797.html>

⁹<https://www.netall.ru/transport/news/1136717.html>

¹⁰<https://www.netall.ru/incidents/news/1136624.html>

¹¹<https://www.netall.ru/incidents/news/1136580.html>

¹²<https://www.netall.ru/sport/news/1136564.html>

¹³<https://www.netall.ru/society/news/1136381.html>

¹⁴<https://www.netall.ru/realty/news/1136372.html>

¹⁵<https://www.netall.ru/medicine/news/1136287.html>

¹⁶<https://www.netall.ru/realty/news/1131857.html>